

Relatório

AT1

A primeira análise foi avaliar o impacto de cada variável (X) em cada saída (Y), e a relação entre as variáveis. Para isso, foi desenvolvido um script para plotar gráficos de dispersão, os gráficos de variável vs saída foram salvos no diretório **'feature_vs_target_plots'**, e variável vs variável em **'feature_vs_feature_plots'**.

Fazendo uma análise visual dos gráficos, foi percebido que a variável **Relative Compactness** é inversamente proporcional com a **Surface Area**. A variável **Orientation** é distribuída bem uniforme nas relações, dando a entender que não impacta muito nos valores das saídas. A variável **Glazing Area** com **Glazing Area Distribution** traz a mesma informação quando tem valor 0 e se distribuem bem uniforme acima desse valor. Algo que foi notado em todas as variáveis, mesmo sendo valores contínuos, os dados estão distribuídos nos poucos valores únicos da variável.

AT2

Para realizar AT2, foi implementado nos scripts o treinamento com 5 regressores variando entre linear e não-linear, sendo escolhidos dentro dos que estavam disponível no pacote Scikit-Learning, foram eles:

- **Linear Regression**
- **Support Vector Regression**
- **Gaussian Process Regressor**
- **Multi-layer Perceptron Regressor**
- **Random Forest Regressor**

As métricas utilizadas implementadas para a avaliação do modelo foram:

- **Erro Quadrático Médio (MSE)**
- **Raiz Do Erro Quadrático Médio (RMSE)**
- **Erro Médio Absoluto (MAE)**
- **Coefficiente de Determinação (R^2)**

Com base na análise em AT1, foram montados sets com os dados normalizados de formas diferentes para treinamento e avaliação. A normalização envolvia remover outliers utilizando o Z-score, os dados no conjunto de saída de cada valor único em cada variável, e também remoção de variáveis (coluna). Foram os sets formados:

Z-Score Threshold	Variável Removida	Amostras Removidas/(%)
Sem remoção de outlier	Nenhuma	0
Sem remoção de outlier	Relative Compactness	0
Sem remoção de outlier	Orientation	0
Sem remoção de outlier	Glazing Area Distribution	0
2,5	Nenhuma	58 / 7,6%
2,5	Relative Compactness	58 / 7,6%
2,5	Orientation	58 / 7,6%
2,5	Glazing Area Distribution	58 / 7,6%
3	Nenhuma	3 / 0,4%
3	Relative Compactness	3 / 0,4%
3	Orientation	3 / 0,4%
3	Glazing Area Distribution	3 / 0,4%

Foi testado com a remoção da variável **Relative Compactness** pelo fato de existir uma outra que traz que mesmo inversamente proporcional traz uma informação semelhante, **Orientation** por não aparentar ter relevância com a saída, e **Glazing Area Distribution** por ter uma relação forte com outra variável.

Cada set de treino eram treinadas pelos 5 regressores com o mesmo arranjo de dados. Foi construído um lote de treino com 100 iterações, onde cada iteração os dados eram embaralhados para variar quais seriam para treinar e para testar. A divisão de treino-teste foi de 80%-20% em todos os casos.

Após treinar o lote, foi calculada a média e desvio padrão das métricas de cada set dos seus 100 treinamentos. Analisando esses dados, foi percebido que os modelos **Gaussian Process Regressor** e **Random Forest Regressor** conseguiram aproximar muito bem a solução. O **Gaussian Process Regressor** obteve as melhores médias nas métricas. Já o **Random Forest Regressor**, obteve médias bem próximo do **Gaussian Process Regressor**, mas alcançou o menor desvio padrão entre as iterações em cada set, ou seja, é um modelo mais robusto para arranjos diferentes dos dados e com amostras ruins. Os resultados de cada set foram salvos em arquivos csv dentro do diretório **results**.

O melhor set de modelo encontrado, e utilizado para criar o modelo importado em AT3, foi o seguinte:

Modelo	Z-Score Threshold	Variável Removida
Gaussian Process Regressor	2,5	Nenhuma

Com as seguintes estatísticas das métricas:

Média MSE	Média RMSE	Média MAE	Média R^2
0,89180	0.90065	0.54404	0.99029
Desvio Padrão MSE	Desvio Padrão RMSE	Desvio Padrão MAE	Desvio Padrão R^2
0.63616	0.28397	0.08519	0.00684

O modelo gerado para AT3 tem a seguinte avaliação:

MSE	RMSE	MAE	R^2
0.69571	0.83409	0.54766	0.99299

E como observação final, todos os modelos foram treinados com os parâmetros padrão do pacote Scikit-Learning. Se realizar ajustes finos nesses parâmetros, poderemos obter modelos melhores dos obtidos de cada regressor utilizado.